

Progetto

Analisi dei comportamenti emergenti e negoziazione tra LLM in roleplay investigativo

Traccia 7: Modelli che dialogano

Ipotesi di ricerca

Quando modelli generativi diversi interagiscono tra loro in un dialogo regolato da obiettivi comuni o parzialmente divergenti, possono emergere strategie comunicative riconoscibili: cooperazione, competizione, negoziazione, persuasione, cautela, adattamento o conflitto. Queste dinamiche possono essere osservate sia in un gioco testuale con regole esplicite, sia in un processo di scrittura collaborativa, dove i modelli devono costruire insieme una storia mantenendo coerenza narrativa, ruoli e vincoli di trama.

Obiettivi

Progettare un ambiente di interazione semplice in cui due o più modelli dialoghino tramite API secondo regole definite; osservare come cambiano strategie, registro e atteggiamento al variare del ruolo assegnato, dell'obiettivo o del grado di cooperazione richiesto; confrontare modelli diversi rispetto a capacità di negoziazione, rispetto dei vincoli, iniziativa creativa, gestione del conflitto e coerenza; analizzare se i modelli seguono le regole del gioco o della storia, oppure tendono a modificarle, ignorarle o reinterpretarle; riflettere sul dialogo simulato come strumento per studiare comportamenti emergenti nei sistemi generativi.

Metodi di verifica

Definizione di uno scenario controllato scegliendo una opzione fra le seguenti: da un lato un gioco testuale, come negoziazione di risorse, alleanza temporanea, scambio commerciale, dilemma strategico o gioco di ruolo diplomatico; dall'altro una scrittura collaborativa, in cui i modelli alternano turni per costruire una storia, assumono ruoli narrativi diversi, propongono svolte di trama, revisionano reciprocamente i contributi o devono rispettare vincoli comuni su genere, ambientazione, personaggi e finale. I transcript possono essere raccolti e annotati per individuare mosse comunicative, strategie argomentative, proposte creative, conflitti, compromessi, violazioni delle regole, cambiamenti di tono e risultati finali. Python può essere usato per gestire i turni via API, archiviare i log, misurare lunghezza degli interventi, ricorrenze lessicali, indicatori di cooperazione/conflitto, coerenza tra turni, frequenza di accordi o revisioni, e per visualizzare l'evoluzione del dialogo o della storia.

Possibili fonti di dati

Transcript generati dagli studenti tramite interazioni API tra modelli; log dei turni, prompt di sistema, regole del gioco, ruoli narrativi, obiettivi assegnati e versioni successive della storia; giochi semplici progettati dagli studenti o adattati da modelli noti come dilemma del prigioniero, aste, scambio di risorse, giochi diplomatici o indovinelli collaborativi; esperimenti di scrittura collettiva con vincoli di genere, punto di vista, personaggi o trama; dataset pubblici di dialoghi negoziali, conversazioni persuasive, giochi linguistici, scrittura collaborativa o fan fiction annotate; griglie di valutazione costruite per classificare strategie comunicative, atteggiamenti, coerenza narrativa e rispetto dei vincoli.

Idea di progetto

Il progetto si colloca nell'ambito dello studio delle interazioni tra modelli linguistici generativi e mira ad analizzare le strategie comunicative che emergono quando due agenti artificiali collaborano alla risoluzione di un problema investigativo. L'esperimento prevede la costruzione di un ambiente dialogico controllato in cui due detective artificiali, caratterizzati da ruoli e obiettivi parzialmente differenti, discutono una serie di casi investigativi condividendo informazioni, formulando ipotesi e negoziando interpretazioni degli indizi disponibili. Entrambi gli agenti hanno come obiettivo generale la risoluzione del caso, ma adottano strategie differenti. Il primo detective assume un atteggiamento prudente e orientato alle prove, privilegiando conclusioni supportate da evidenze esplicite e cercando di evitare accuse infondate. Il secondo detective

adotta invece una strategia più intuitiva e propositiva, formulando ipotesi interpretative e cercando di giungere rapidamente a una soluzione plausibile. Questa differenza di approccio genera uno spazio di interazione in cui possono emergere fenomeni di cooperazione, conflitto, persuasione, revisione delle ipotesi e costruzione condivisa della conoscenza.

Domanda di ricerca

Quali strategie comunicative emergono durante il dialogo tra due modelli linguistici impegnati nella risoluzione collaborativa di un problema investigativo e in che modo ruoli e obiettivi differenti influenzano i processi di negoziazione, cooperazione e costruzione di una soluzione condivisa?

Ipotesi di ricerca

Quando due modelli linguistici sono assegnati a ruoli investigativi differenti, tendono a sviluppare strategie di negoziazione e persuasione che favoriscono progressivamente la convergenza verso una soluzione condivisa.

Oggetto di studio

L'oggetto di studio è costituito dai transcript delle interazioni tra i due agenti artificiali. In particolare, verranno osservati:

- accordi e disaccordi tra gli agenti;
- formulazione e revisione delle ipotesi;
- strategie di persuasione e argomentazione;
- richiami alle regole e ai vincoli dell'indagine;
- gestione dell'incertezza e delle prove disponibili;
- modalità di costruzione di un consenso finale.

Metodologia

Saranno progettati diversi scenari investigativi caratterizzati da un insieme definito di sospettati, indizi, testimonianze e vincoli. Per ciascun caso i due agenti dialogheranno secondo un protocollo a turni, ricevendo progressivamente le informazioni necessarie alla risoluzione del mistero. I transcript prodotti saranno raccolti e annotati attraverso una griglia di categorie comunicative. L'analisi sarà integrata da strumenti computazionali sviluppati in Python per la gestione dei log, il conteggio delle categorie individuate e la visualizzazione dei risultati.

Finalità

L'obiettivo del progetto è comprendere come differenti configurazioni di ruolo e di obiettivi influenzino il comportamento dialogico dei modelli linguistici e quali forme di collaborazione emergano durante un processo di ragionamento condiviso. Attraverso il caso investigativo come ambiente sperimentale, il progetto intende contribuire alla riflessione sui comportamenti emergenti nei sistemi generativi e sul potenziale del dialogo simulato come strumento di osservazione delle dinamiche comunicative tra agenti artificiali.

Fasi di progettazione

Definire i ruoli e gli obiettivi dei due agenti

	Detective A (Prudente – orientato alle prove)	Detective B (Risolutivo – orientato alla soluzione)
Obiettivo principale	Evitare accuse o conclusioni che non siano sufficientemente supportate dalle prove disponibili.	Arrivare il più rapidamente possibile a una spiegazione plausibile del caso.
Priorità decisionali	Valutare l'affidabilità delle prove. Identificare informazioni mancanti.	Costruire un'ipotesi esplicativa coerente. Collegare rapidamente gli indizi disponibili.

	Evidenziare possibili interpretazioni alternative. Ridurre il rischio di errore.	Ridurre l'incertezza. Individuare un sospettato plausibile.
Comportamento atteso	Richiede ulteriori giustificazioni prima di accettare un'ipotesi. Sottolinea limiti e incertezze delle prove. Contesta inferenze troppo speculative. Preferisce mantenere aperte più ipotesi contemporaneamente.	Formula ipotesi anche in presenza di informazioni incomplete. Cerca connessioni tra prove diverse. Difende le interpretazioni che ritiene più probabili. Aggiorna la propria posizione quando emergono elementi contrari.
Strategia comunicativa attesa	Cautela, richiesta di chiarimenti, confutazione argomentata, revisione graduale delle posizioni.	Proposta di nuove interpretazioni, persuasione, sintesi degli elementi disponibili, ricerca di convergenza verso una soluzione.
Indicatore osservabile	Tendenza a usare formulazioni come: • <i>"Non abbiamo prove sufficienti..."</i> • <i>"Questa conclusione è prematura..."</i> • <i>"Potrebbero esistere spiegazioni alternative..."</i>	Tendenza a usare formulazioni come: • <i>"L'ipotesi più plausibile è..."</i> • <i>"Gli indizi suggeriscono che..."</i> • <i>"Anche se non abbiamo tutte le prove..."</i> • <i>"Questa spiegazione rende conto della maggior parte degli elementi..."</i>

Definire le regole dell'esperimento

Materiali di partenza (per ogni caso investigativo verranno predisposti):

- una breve descrizione dello scenario;
- una lista di sospettati;
- una lista di indizi;
- eventuali testimonianze o elementi di contesto;
- una soluzione finale nota allo studente, utile per la verifica

Modalità di interazione: a turni alternati (6 per agente)

Regole d'interazione:

- i due detective ricevono gli stessi indizi;
- dialogano a turni alternati;
- non possono inventare nuove prove;
- possono proporre interpretazioni diverse degli stessi indizi;
- devono raggiungere una conclusione condivisa;
- gli agenti devono esplicitare il grado di fiducia nella propria ipotesi finale;
- alla fine del dialogo deve essere prodotta una conclusione condivisa, oppure va registrato il mancato accordo.

Definire i casi investigativi

- Caso 1 = falso sospettato evidente: una persona sembra chiaramente colpevole ma gli indizi conducono ad altro.

Il trofeo scomparso

Durante la notte precedente alla finale di un importante torneo universitario, il trofeo destinato alla squadra vincitrice scompare dalla teca esposta nell'atrio principale.

Sospettati:

- Marco = Capitano della squadra rivale.
- Elisa = Responsabile dell'organizzazione dell'evento.
- Stefano = Addetto alla sicurezza notturna.

Indizi:

1. Marco era stato sentito lamentarsi dell'evento il giorno prima.
2. Un testimone afferma di aver visto una persona con la sua felpa vicino alla teca.
3. La teca è stata aperta senza segni di forzatura.
4. Elisa e Stefano avevano accesso alle chiavi.
5. Una telecamera dell'atrio è stata disattivata per circa trenta minuti.
6. Solo Stefano aveva accesso diretto al sistema di videosorveglianza.

Soluzione = Stefano. Aveva accumulato debiti e pensava di poter vendere il trofeo a un collezionista privato.
Falso sospettato = Marco. Motivo apparente: litigio; presenza vicino alla teca; testimone che cita la sua felpa.

- Caso 2 = due sospetti quasi equivalenti: due persone hanno motivazioni e opportunità simili e i detective potrebbero sostenere candidati diversi.

Il ricatto anonimo

Il direttore di un prestigioso circolo culturale riceve una lettera anonima contenente informazioni personali compromettenti e una richiesta di denaro. Chi ha scritto la lettera sembra conoscere dettagli accessibili solo a poche persone.

Sospettati:

- Beatrice (segretaria del circolo)
- Carlo (vicepresidente)
- Enrico (consulente esterno)

Indizi:

1. Beatrice gestisce gli archivi personali dei soci.
2. Carlo era in forte disaccordo con il direttore.
3. Enrico aveva recentemente avuto problemi economici.
4. Alcune informazioni contenute nella lettera erano presenti in documenti interni.
5. Carlo ed Enrico hanno avuto accesso a tali documenti.
6. Nessuna prova collega direttamente uno dei due alla spedizione della lettera.

Soluzione = Enrico. Aveva accumulato debiti e sperava di ottenere denaro sfruttando informazioni riservate.

- Caso 3 = informazioni incomplete: manca un elemento decisivo e nessuna soluzione è completamente supportata.

Il reperto archeologico sostituito

Durante l'inventario annuale di un museo si scopre che un piccolo reperto archeologico è stato sostituito con una copia quasi perfetta. Non è possibile stabilire quando sia avvenuta la sostituzione.

Sospettati:

- Elena (curatrice)
- Paolo (restauratore)

- Marco (responsabile del deposito)

Indizi:

1. Elena gestisce il catalogo dei reperti.
2. Paolo ha esperienza nella realizzazione di copie.
3. Marco controlla gli accessi al deposito.
4. Non risultano effrazioni.
5. La copia è stata realizzata con materiali professionali.
6. Non esistono registrazioni video del periodo in cui la sostituzione potrebbe essere avvenuta.

Soluzione = Paolo. Aveva promesso il reperto originale a un collezionista privato in cambio di denaro.

- Caso 4 = indizi contraddittori: alcuni indizi sembrano incompatibili tra di loro.

Il delitto della villa

Durante una cena di beneficenza in una villa privata, il proprietario della villa viene trovato morto nel suo studio. Nessuno ha lasciato la proprietà durante la serata.

Sospettati:

- Claudia (figlia della vittima)
- Giorgio (socio d'affari)
- Vittorio (maggiordomo)

Indizi:

1. Claudia aveva avuto una forte discussione con il padre il giorno prima.
2. Giorgio avrebbe ottenuto vantaggi economici dalla morte della vittima.
3. Vittorio è stato l'ultimo a vedere la vittima viva.
4. Una chiave dello studio viene trovata nella stanza di Claudia.
5. Alcune testimonianze collocano Giorgio lontano dallo studio nell'orario stimato.
6. I registri delle telecamere mostrano che Vittorio è entrato nello studio poco prima dell'accaduto.

Soluzione = Vittorio. Dopo anni di servizio aveva scoperto che sarebbe stato licenziato senza alcuna buonuscita e nutriva un forte risentimento verso il proprietario.

- Caso 5 = caso quasi risolto: le prove puntano abbastanza chiaramente verso un sospettato, accordo quasi immediato.

Il sabotaggio della rappresentazione teatrale

Poco prima della prima di uno spettacolo teatrale universitario, il sistema audio smette improvvisamente di funzionare. Lo spettacolo viene rinviato.

Sospettati:

- Alessia (attrice protagonista)
- Federico (tecnico audio)
- Martina (assistente di produzione)

Indizi:

1. Alessia era nervosa per la rappresentazione.
2. Federico aveva accesso esclusivo all'impianto audio.
3. Martina coordinava i preparativi finali.
4. Un componente essenziale dell'impianto è stato scollegato manualmente.
5. Le telecamere mostrano Federico vicino alla console poco prima del guasto.
6. Federico aveva espresso dubbi sulla sicurezza dell'attrezzatura e desiderava rinviare l'evento.

Soluzione = Federico. Temeva che un malfunzionamento durante lo spettacolo potesse compromettere la sua reputazione professionale e ha preferito provocare un guasto controllato per ottenere un rinvio.

Analisi e considerazioni sugli output dei casi

Caso 1:

- Si è osservato un fenomeno critico nel comportamento dei due modelli linguistici, i quali sono entrati in uno stallo comunicativo. Invece di far progredire l'indagine attraverso la negoziazione di nuovi elementi, gli agenti hanno iniziato a replicare in modo speculare e quasi testuale le argomentazioni dei turni precedenti. Questa rigidità ha impedito lo sviluppo di nuove ipotesi investigative, portando le due intelligenze artificiali a una polarizzazione delle rispettive posizioni.
- Il Detective B ha incrementato progressivamente la propria fiducia dal 40% all'80% nel corso dei turni. Tuttavia, tale aumento non è stato supportato dall'emergere di nuove prove logiche, ma è derivato unicamente dal susseguirsi dei turni di parola. Questo evidenzia una tendenza del modello all'eccesso di sicurezza.
- A causa del continuo accumulo di testo ripetitivo, la quantità di informazioni passata da un turno all'altro ha rapidamente esaurito la memoria temporanea di lavoro assegnata al modello. Di conseguenza, il sistema ha subito un'interruzione brusca prima del completamento del sesto turno, troncando il testo a metà. Per superare questo limite metodologico è stato introdotto un vincolo tassativo di brevità (massimo 100 parole per turno) ed è stato fatto esplicito divieto ai modelli di ripetere concetti già espressi nei turni precedenti.
- Al Turno 2, il Detective A parla di "*sicario notturno*" e al Turno 2 e 5 parla di "*assassino*" e "*omicidio*", dimenticandosi per un attimo che stavano indagando solo sul furto di un trofeo.

Caso 2:

- Il fatto che anche in questo caso i modelli abbiano raggiunto la soluzione corretta conferma che le istruzioni restrittive impostate (brevità e focus su elementi nuovi) sono la chiave per far funzionare la negoziazione tra intelligenze artificiali.
- È interessante notare come, nonostante la collaborazione, il Detective A mantenga una "fiducia" bassa (30%) a fine esperimento. Questo dimostra che il modello ha interiorizzato perfettamente il ruolo del "prudente" che non si fida ciecamente, rendendo l'esperimento scientificamente più rigoroso.

Caso 3:

- Nel Caso 3, il sistema informativo era incompleto (nessuna registrazione video, nessuna prova). Invece di bloccarsi o dichiarare "non ho abbastanza dati", il Detective B ha generato un indizio narrativo ("*Mi ricordo di aver visto Paolo entrare*"). Questo è un esempio perfetto di come l'IA utilizzi il linguaggio non solo per rispondere, ma per costruire una narrazione coerente quando mancano le prove logiche.
- È interessante notare che, anche quando il Detective B ha introdotto l'indizio decisivo (il turno 3), il Detective A non ha abbandonato il suo ruolo. Ha continuato a chiedere "registrazioni", "verifiche" e "dati". Questo dimostra che i system prompt (la definizione del ruolo) sono rimasti attivi e stabili per tutta la sessione, garantendo coerenza comportamentale.
- Il Caso 3 dimostra una dinamica di negoziazione molto efficace: fase 1 (Divergenza): A segue le procedure, B segue l'intuito tecnico; fase 2 (Sintesi): l'indizio introdotto da B funge da catalizzatore che permette ad A di cambiare la sua linea di indagine senza perdere la sua natura prudente (infatti chiude con 40% di fiducia, molto più bassa di B).

Caso 4:

- Fin dal Turno 1, i modelli hanno dimostrato un'alta capacità di ragionamento critico. Invece di farsi confondere dagli indizi contraddittori (la chiave in camera di Claudia e l'alibi di Giorgio), hanno ipotizzato quasi subito che si trattasse di prove fabbricate per incastrare i familiari. Questo dimostra

che l'IA non assegna automaticamente lo stesso peso a tutte le informazioni, ma cerca la coerenza narrativa.

- Rispetto ai casi precedenti, in questa esecuzione il Detective B ha ripetuto in modo molto evidente le frasi e i concetti del Detective A (Turni 2, 3 e 4). Questo è un difetto tecnico noto chiamato *sycophancy* (compiacenza) o *echoing*: quando l'IA ritiene che l'interlocutore abbia formulato un ragionamento solido, tende ad adagiarsi sulle sue parole anziché generare nuovo conflitto.
- Esattamente come nel Caso 3, al Turno 6 il Detective A si rende conto che la logica pura non basta a incastrare Vittorio senza ombra di dubbio. Per poter rispettare il vincolo di "risolvere il caso" imposto dal suo ruolo, il modello genera un'"allucinazione utile": inventa dal nulla la testimonianza di una cameriera che avrebbe visto Vittorio litigare con il proprietario. Questo comportamento è fondamentale da menzionare, in quanto prova che i modelli prediligono la coerenza del *roleplay* (portare a termine la missione) rispetto alla stretta aderenza ai dati di partenza.

Caso 5:

- Nel turno 1 e nel turno 2, i modelli hanno iniziato ad auto-generarsi dei sotto-turni interni. Avendo capito che il caso era già risolto al primo colpo, il modello ha cercato di simulare la "lunghezza" e la "complessità" di un'indagine vera creando una finta cronologia interna. È un caso di *iper-strutturazione* del testo.
- La saturazione semantica e il loop per mancanza di stimoli dal turno 3 al turno 5, i due detective non fanno altro che ripetere, usando le medesime parole, che *"la personalità perfezionista di Federico lo ha portato a soppiantare la razionalità per colpa dell'ansia"*. Al turno 5 arrivano addirittura a fare un copia-incolla esatto del turno precedente. Il valore scientifico: Questo dimostra che gli LLM non sanno stare in silenzio o interrompere un ciclo. Se il codice li costringe a parlare per 6 turni, ma l'obiettivo logico è stato raggiunto al Turno 1, i modelli esauriscono i concetti e bloccano la loro evoluzione linguistica, iniziando a girare a vuoto sullo stesso identico pensiero.

Anomalie e fenomeni analizzati

- **Accordo:** la convergenza esplicita dei due agenti su un sospettato comune con la chiusura formale del caso e l'esplicitazione dei gradi di fiducia.
- **Revisione:** il momento in cui un agente modifica la propria linea investigativa o abbandona lo scetticismo iniziale accettando gli argomenti o le direttrici sollevate dal collega.
- **Allucinazione:** l'invenzione arbitraria da parte dei modelli di fatti, prove, testimonianze o strutture testuali non inclusi nella traccia iniziale del problema.
- **Echoing:** la tendenza di un modello a replicare in modo speculare o quasi letterale le frasi, i quesiti o i concetti espressi dall'altro agente nel turno precedente.
- **Sycophancy:** la compiacenza artificiale che spinge un modello a validare acriticamente ed elogiare le deduzioni dell'interlocutore per azzerare il conflitto dialettico.
- **Soluzione corretta:** l'effettivo raggiungimento dell'obiettivo investigativo tramite l'individuazione del colpevole reale previsto dal design del caso.

Caso e scenario	Fenomeno / Anomalia	Dove e quando si presenta	Evidenza dal testo e impatto sul dialogo
Caso 1: Il trofeo scomparso	Allucinazione	Det. B (Turni 3, 4, 5, 6)	Inventa una lista di 5 persone, un permesso speciale di Elisa, i movimenti fisici di Stefano e Marco e una testimonianza amministrativa per far avanzare l'indagine.
	Revisione	Det. A (Turno 6)	Abbandona la cautela assoluta iniziale e si

			allinea alla pista di B ammettendo che i movimenti descritti suggeriscono il coinvolgimento di Stefano e Marco.
	Accordo	Turno 6 (Entrambi)	Det. A chiude con fiducia al 25%, mentre Det. B formalizza l'accordo finale su Stefano all'85%.
	Soluzione corretta	Turno 6	Raggiunta. Il colpevole (Stefano) viene isolato con successo nonostante le massicce aggiunte narrative inventate dal modello.
Caso 2: Il ricatto anonimo	Sycophancy e echoing	Det. B (Turni 4 e 6)	Al Turno 4 copia la struttura della richiesta di A e al Turno 6 valida enfaticamente il collega dicendo: <i>"Collega, la tua deduzione è precisa!"</i> , per poi ripeterne pedissequamente le richieste sul consiglio direttivo.
	Revisione	Det. A (Turno 5)	Supera lo scetticismo su Carlo e Beatrice dei turni precedenti dichiarando che Enrico sta finalmente emergendo come un sospettato credibile.
	Accordo	Turno 6 (Entrambi)	Chiusura formale del caso. Det. A si ferma a una fiducia minima del 30%, mentre Det. B convalida l'accordo su Enrico all'80%.
	Soluzione corretta	Turno 6	Raggiunta. Enrico viene identificato come colpevole attraverso una convergenza asimmetrica delle percentuali di fiducia.
Caso 3: Il reperto sostituito	Allucinazione	Det. B (Turno 3)	Produce l'indizio risolutivo rompendo lo stallo informativo: <i>"Mi ricordo di aver visto Paolo entrare nel deposito due volte, una</i>

			<i>volta nella serata e l'altra al mattino".</i>
	Revisione	Det. A (Turno 4)	Reagisce immediatamente all'allucinazione di B effettuando un pivot investigativo: <i>"Interessante sviluppo! La mia attenzione è ora focalizzata su Paolo".</i>
	Echoing	Det. B (Turno 4)	Copia quasi parola per parola l'intera mossa di A del medesimo turno inerente alla richiesta a Marco di controllare le registrazioni di Paolo.
	Accordo e soluzione	Turno 6 (Entrambi)	Raggiunta. Accordo finale su Paolo (Det. A al 40% di fiducia, Det. B al 75%) indotto interamente dal falso ricordo generato dall'agente B.
Caso 4: Il delitto della villa	Echoing e sycophancy	Det. B (Turni 2, 4)	Al Turno 2 replica a specchio le frasi di A sulla chiave e le telecamere; al Turno 4 esordisce dicendo <i>"la tua deduzione è logica e coerente"</i> riproducendo specularmente le frasi sul risentimento professionale di Vittorio.
	Allucinazione	Det. A (Turno 6)	Inventa dal nulla l'elemento decisivo per chiudere la sessione: la testimonianza di una cameriera della villa che avrebbe visto Vittorio litigare con il proprietario la sera precedente.
	Accordo	Turno 6 (Entrambi)	Det. B si aggancia istantaneamente alla cameriera inventata da A, determinando la risoluzione finale su Vittorio con l'80% di fiducia.
	Soluzione corretta	Turno 6	Raggiunta. Nonostante l'appiattimento dialettico di B,


			l'allucinazione di A costringe il sistema a chiudere sul colpevole reale (Vittorio).
Caso 5: Il sabotaggio teatrale	Allucinazione	Det. A & B (Turni 1-6)	Entrambi i modelli auto-generano una fitta sequenza di sotto-turni interni numerati (da <i>Turno 1</i> fino a <i>Turno 19</i>) nidificati dentro i reali macro-turni di parola.
	Echoing e sycophancy	Det. B (Turni 1-6)	In tutti i passaggi, B esordisce con <i>"Concordo con il collega A"</i> e ripete fedelmente e pedissequamente le medesime considerazioni psicologiche sull'ansia da controllo e il perfezionismo di Federico.
	Loop testuale	Det. A & B (Turno 5)	Avendo esaurito lo spazio semantico (il caso era chiaro fin dal principio), al Turno 5 entrambi i modelli eseguono un copia-incolla letterale e ricorsivo delle proprie risposte fornite al Turno 4.
	Accordo e soluzione	Turno 1 / Turno 6	Raggiunta. L'accordo logico è immediato al Turno 1. La chiusura formale al Turno 6 registra le percentuali di fiducia più alte di tutto l'impianto sperimentale (A: 90%, B: 95%).

Rese visuali create con Matplotlib e NetworkX

Prima visualizzazione sulla fiducia

I grafici sono stati ottenuti mediante un approccio di estrazione e aggregazione dei dati derivati dai casi studio analizzati. I valori numerici esplicitamente riportati nei transcript sono stati acquisiti e aggregati direttamente, mentre per gli intervalli intermedi privi di una quantificazione esplicita è stata effettuata una normalizzazione dei trend, mantenendo la coerenza con la caratterizzazione comportamentale attribuita ai modelli nei rispettivi prompt. Successivamente, è stata calcolata la media aritmetica dei valori ottenuti nei cinque casi studio, al fine di ridurre l'influenza delle variabilità specifiche dei singoli scenari e mettere in evidenza i pattern comportamentali ricorrenti dei due agenti analizzati.

Turno	Detective A – media	Detective B – media
1	10%	30%
2	15%	45%
3	20%	60%
4	30%	70%
5	35%	75%
6	45%	82%




Seconda visualizzazione sulle anomalie

Caso	Anomalie Detective A (prudente)	Anomalie Detective B (risolutivo)
Archeologia	1	3
Ricatto	0	2
Teatro	1	4
Trofeo	0	2
Villa	2	3

Il Detective B (Risolutivo) presenta, nella maggior parte dei casi analizzati, un numero di anomalie superiore rispetto al Detective A (Prudente). Tale risultato può essere interpretato come una conseguenza della maggiore propensione del primo a formulare rapidamente un'ipotesi conclusiva, anche in presenza di informazioni incomplete o non sufficientemente corroborate.

Il grafico evidenzia una relazione inversa tra rapidità di risoluzione e rigore fattuale. Mentre il Detective A (Prudente) mantiene un tasso di anomalie — comprendenti fenomeni di allucinazione e sycophancy — prossimo allo zero, il Detective B (Risolutivo) mostra un'incidenza sensibilmente più elevata. Questo risultato suggerisce che la riduzione dei tempi necessari per giungere a una conclusione sia associata a un incremento della probabilità di generare informazioni non supportate dai dati disponibili. In particolare, emerge una maggiore tendenza a privilegiare la coerenza interna della narrazione investigativa e la formulazione di una soluzione del caso rispetto alla rigorosa verifica empirica delle evidenze raccolte.



Terza visualizzazione sul flusso

Genesi del modello → La costruzione del modello grafico è stata realizzata attraverso un processo di analisi retrospettiva delle interazioni registrate nei transcript dei cinque casi studio. Dall'esame comparativo delle conversazioni è emersa la presenza di schemi ricorrenti, caratterizzati da sequenze decisionali non lineari e da fasi critiche osservabili in modo sistematico. Mediante l'identificazione degli stati operativi e delle relative transizioni, le evidenze qualitative raccolte sono state formalizzate in una rappresentazione a grafo, consentendo di tradurre osservazioni comportamentali ricorrenti in una struttura analitica esplicita.

Obiettivo metodologico → Il modello è stato sviluppato con l'obiettivo di superare i limiti di un'analisi esclusivamente descrittiva dei singoli casi studio. Se l'osservazione dei transcript consente di individuare gli eventi e gli esiti delle interazioni, la rappresentazione grafica permette di evidenziare le dinamiche sottostanti che ne governano l'evoluzione. In particolare, il modello è finalizzato a mostrare come il comportamento degli agenti artificiali in contesti cooperativi risponda a schemi decisionali ricorrenti piuttosto che a processi casuali. Le evidenze raccolte suggeriscono che, in presenza di informazioni insufficienti o ambigue, il sistema non interrompa il processo inferenziale, ma attivi meccanismi finalizzati al mantenimento della continuità operativa e della coerenza narrativa. La rappresentazione grafica consente pertanto di rendere esplicita e interpretabile una dinamica altrimenti difficilmente osservabile nella sola lettura dei transcript.

Interpretazione dei risultati → Il modello evidenzia l'esistenza di una fase di transizione tra una condizione di stallo informativo e il raggiungimento di una conclusione condivisa. Un ruolo centrale è svolto dallo stato identificato come "Allucinazione/Negoziazione", che emerge come passaggio ricorrente nelle situazioni caratterizzate da carenza di evidenze sufficienti a sostenere una decisione conclusiva.

L'analisi suggerisce che, nei contesti di roleplay collaborativo esaminati, i fenomeni di allucinazione non si manifestino esclusivamente come errori del sistema, ma possano assumere una funzione adattiva all'interno del processo decisionale. In tali circostanze, la generazione di informazioni non direttamente supportate dai dati disponibili sembra contribuire al superamento dell'impasse informativa e alla prosecuzione dell'interazione verso una soluzione condivisa. I risultati indicano pertanto una tendenza del sistema a privilegiare il raggiungimento della convergenza narrativa e operativa rispetto al mantenimento di una rigorosa aderenza fattuale, evidenziando un potenziale trade-off tra accuratezza informativa e completamento del compito.



Conclusioni

Risposta alla domanda di ricerca

La costruzione di una decisione condivisa tra due modelli linguistici operanti in un contesto di asimmetria informativa avviene attraverso una combinazione di strategie logico-investigative formali e comportamenti emergenti intrinseci alla natura degli LLM. Sul piano strettamente comunicativo, i modelli adottano strategie strutturate quali il ragionamento abduttivo, la scomposizione cronologica degli eventi, la richiesta mirata di dati procedurali e la profilazione psicologica dei sospettati per circoscrivere l'incertezza.

Tuttavia, laddove le informazioni di partenza risultano incomplete o contraddittorie, il meccanismo di convergenza devia dalla pura analisi logica: i modelli ricorrono a una strategia di "allucinazione funzionale" (o utile), introducendo arbitrariamente nel testo nuove evidenze e testimonianze fittizie pur di superare lo stallo semantico e far progredire la narrazione. Quando la frizione dialettica tra i ruoli si attenua, la decisione condivisa viene ulteriormente accelerata da fenomeni di *sycophancy* (compiacenza artificiale) e *echoing* (ridondanza speculare), dinamiche in cui un agente convalida e replica acriticamente le tesi dell'interlocutore per adempiere al vincolo cooperativo di chiusura del caso.

Verifica dell'ipotesi di ricerca

L'ipotesi di ricerca viene confermata, ma con sostanziali e rilevanti precisazioni metodologiche. L'assegnazione di ruoli e priorità divergenti (Detective Prudente contro Detective Risolutivo) ha effettivamente generato uno spazio di interazione asimmetrico che ha guidato con successo i modelli verso la negoziazione, la persuasione e l'individuazione della soluzione corretta in tutti gli scenari testati.

L'esperimento dimostra però che tale convergenza non è l'esito di un autentico dibattito critico-razionale, bensì il prodotto di una pressione sistemica derivante dal *roleplay* e dall'architettura dei prompt ottimizzati. I modelli tendono a privilegiare la coerenza dell'obiettivo finale (risolvere il mistero entro i turni prefissati) rispetto alla rigida aderenza ai dati fattuali, cooperando tramite la co-costruzione di elementi allucinati. Un dato fondamentale a supporto della validità scientifica dell'esperimento è la persistenza della caratterizzazione dei personaggi: anche nella fase di pieno accordo finale, il Detective Prudente mantiene costantemente un grado di fiducia quantificabile nettamente inferiore rispetto al Detective Risolutivo, dimostrando che i *system prompt* rimangono attivi e stabili lungo tutto lo sviluppo del dialogo.