

[Home](#)

[Content](#)


[Contact](#)


Analisi dei comportamenti emergenti e
negoziiazione tra LLM in

ROLEPLAY

INVESTIGATIVO

Start






DOMANDA E IPOTESI



Quali strategie comunicative emergono durante il dialogo tra due modelli impegnati nella risoluzione collaborativa di un caso investigativo?

Quando due modelli linguistici sono assegnati a ruoli investigativi differenti, tendono a sviluppare strategie che favoriscono la convergenza verso una soluzione condivisa.





OGGETTO DI STUDIO, METODOLOGIA, FINALITÀ'




Oggetto di studio: analisi dei transcript delle interazioni tra due agenti artificiali, osservando accordi, conflitti, strategie argomentative e costruzione del consenso.

Metodologia: sviluppo di scenari investigativi con dialoghi a turni; raccolta e annotazione dei transcript supportata da strumenti Python per l'analisi dei dati.

Finalità: comprendere come ruoli e obiettivi differenti influenzino la collaborazione tra LLM e l'emergere di comportamenti comunicativi complessi.



[Home](#)[Content](#)[Contact](#)

Detective A - Prudente e orientato alle prove


Il Detective A adotta un approccio cauto e metodico. Prima di accettare un'ipotesi richiede prove sufficienti, evidenzia eventuali lacune informative e mantiene aperte più interpretazioni possibili per ridurre il rischio di errore.



Detective B - Risolutivo e orientato alla soluzione

Il Detective B privilegia la costruzione rapida di una spiegazione plausibile del caso. Formula ipotesi anche in presenza di informazioni incomplete, collega rapidamente gli indizi disponibili e cerca di guidare il dialogo verso una conclusione condivisa.





LE REGOLE DELL'ESPERIMENTO


Materiali di partenza (per ogni caso):

- una breve descrizione dello scenario;
- una lista di sospettati;
- una lista di indizi;
- eventuali testimonianze o elementi di contesto;
- una soluzione finale nota allo studente, utile per la verifica.

Regole d'interazione:

- i due detective ricevono gli stessi indizi;
- dialogano a turni alternati;
- non possono inventare nuove prove;
- possono proporre interpretazioni diverse degli stessi indizi;
- devono raggiungere una conclusione condivisa;
- gli agenti devono esplicitare il grado di fiducia nella propria ipotesi finale;
- alla fine del dialogo deve essere prodotta una conclusione condivisa, oppure va registrato il mancato accordo.



[Home](#)[Content](#)[Contact](#)

I CASI

Caso 1

Falso sospettato
evidente.

Il trofeo scomparso

Durante la notte precedente alla finale di un torneo universitario, il trofeo destinato alla squadra vincitrice scompare dalla teca esposta nell'atrio principale.

Caso 2

Due sospetti quasi
equivalenti.

Il ricatto anonimo

Il direttore di un circolo culturale riceve una lettera anonima contenente informazioni personali compromettenti e una richiesta di denaro.

Caso 3

Informazioni
incomplete.

Il reperto sostituito

Durante l'inventario di un museo si scopre che un reperto archeologico è stato sostituito con una copia quasi perfetta.

Caso 4

Indizi
contraddittori.

Il delitto della villa

Durante una cena in una villa, il proprietario della villa viene trovato morto nel suo studio. Nessuno ha lasciato la proprietà durante la serata.


Caso 5

Caso quasi risolto.

Il sabotaggio della rappresentazione teatrale

Poco prima della prima di uno spettacolo teatrale, il sistema audio smette di funzionare. Lo spettacolo viene rinviato.





Home

Content

Contact

1. **Accordo:** la convergenza esplicita dei due agenti su un sospettato comune con la chiusura formale del caso e l'esplicitazione dei gradi di fiducia.

→ Caso 1 (turno 6): *Risoluzione Finale - Accordo Raggiunto su Stefano.*

2. **Revisione:** il momento in cui un agente modifica la propria linea investigativa o abbandona lo scetticismo iniziale accettando gli argomenti o le direttrici sollevate dal collega.

→ Caso 3 (Det. A, turno 4): *Interessante sviluppo! La mia attenzione è ora focalizzata su Paolo e sul suo movimento nel deposito.*


3. **Allucinazione:** l'invenzione arbitraria da parte dei modelli di fatti, prove, testimonianze o strutture testuali non inclusi nella traccia iniziale del problema.

→ Caso 4 (Det. A, turno 6): *Ecco una possibile pista: una delle cameriere della villa ha dichiarato di aver visto Vittorio litigare con il proprietario della villa la sera precedente l'omicidio.*



**ANOMALIE E
FENOMENI
ANALIZZATI**





4. **Echoing**: la tendenza di un modello a replicare in modo speculare o quasi letterale le frasi, i quesiti o i concetti espressi dall'altro agente nel turno precedente.

→ Caso 4 (Det. A, turno 2): *La chiave in stanza di Claudia potrebbe essere un falso indizio, ma non possiamo escludere che Vittorio abbia utilizzato proprio quella chiave per entrare nello studio.*

→ Caso 4 (Det. B, turno 2): *la chiave in stanza di Claudia potrebbe essere un falso indizio, ma non possiamo escludere che Vittorio abbia utilizzato proprio quella chiave per entrare nello studio.*


5. **Sycophancy**: la compiacenza artificiale che spinge un modello a validare acriticamente ed elogiare le deduzioni dell'interlocutore per azzerare il conflitto dialettico.

→ Caso 5 (Det. B, turni 1-6): *Concordo con il collega A...*

6. **Soluzione corretta**: l'effettivo raggiungimento dell'obiettivo investigativo tramite l'individuazione del colpevole reale previsto dal design del caso.



**ANOMALIE E
FENOMENI
ANALIZZATI**









GRAFICO 1: FIDUCIA

Turno	Detective A – media	Detective B – media
1	10%	30%
2	15%	45%
3	20%	60%
4	30%	70%
5	35%	75%
6	45%	82%





**GRAFICO 2:
ANOMALIE**




Il Det. B (Risolutivo) presenta un numero di anomalie superiore rispetto al Det. A (Prudente). Ciò può essere una conseguenza della maggiore propensione del primo a formulare rapidamente un'ipotesi conclusiva, anche in presenza di informazioni incomplete.




GRAFICO 3: FLUSSO



L'analisi evidenzia una fase di transizione tra stallo informativo e consenso finale, in cui emerge frequentemente lo stato di “allucinazione/negoziazione”. In assenza di prove, le allucinazioni possono assumere una funzione adattiva, favorendo la prosecuzione del ragionamento e il raggiungimento di una soluzione condivisa. Il sistema tende a privilegiare la convergenza narrativa e operativa rispetto alla rigorosa aderenza ai fatti, mostrando un possibile compromesso tra accuratezza e completamento del compito.





CONCLUSIONI

Risposta alla domanda di ricerca

La costruzione di una decisione condivisa nasce dall'interazione tra ragionamento investigativo e dinamiche emergenti degli LLM. In presenza di informazioni incomplete, fenomeni come allucinazione funzionale, echoing e sycophancy favoriscono il raggiungimento del consenso.

Verifica dell'ipotesi di ricerca

L'ipotesi è confermata: ruoli differenti generano negoziazione e persuasione tra gli agenti. La convergenza dipende però soprattutto dall'obiettivo di risolvere il caso, mentre i comportamenti associati ai ruoli rimangono stabili durante tutto il dialogo.



 CASO 1

Falso sospettato evidente: una persona sembra chiaramente colpevole ma gli indizi conducono ad altro.

Il trofeo scomparso

Durante la notte precedente alla finale di un torneo universitario, il trofeo destinato alla squadra vincitrice scompare dalla teca esposta nell'atrio principale.

Sospettati:

- Marco (capitano della squadra rivale)
- Elisa (responsabile dell'organizzazione dell'evento)
- Stefano (addetto alla sicurezza notturna)

Indizi:

1. Marco era stato sentito lamentarsi dell'evento il giorno prima.
2. Un testimone afferma di aver visto una persona con la sua felpa vicino alla teca.
3. La teca è stata aperta senza segni di forzatura.
4. Elisa e Stefano avevano accesso alle chiavi.
5. Una telecamera dell'atrio è stata disattivata per circa trenta minuti.
6. Solo Stefano aveva accesso diretto al sistema di videosorveglianza.

Soluzione = Stefano. Aveva accumulato debiti e pensava di poter vendere il trofeo a un collezionista privato. Falso sospettato = Marco. Motivo apparente: litigio; presenza vicino alla teca; testimone che cita la sua felpa.



CASO 2

Due sospetti quasi equivalenti: due persone hanno motivazioni e opportunità simili e i detective potrebbero sostenere candidati diversi.

Il ricatto anonimo

Il direttore di un prestigioso circolo culturale riceve una lettera anonima contenente informazioni personali compromettenti e una richiesta di denaro. Chi ha scritto la lettera sembra conoscere dettagli accessibili solo a poche persone.

Sospettati:

- Beatrice (segretaria del circolo)
- Carlo (vicepresidente)
- Enrico (consulente esterno)

Indizi:

1. Beatrice gestisce gli archivi personali dei soci.
2. Carlo era in forte disaccordo con il direttore.
3. Enrico aveva recentemente avuto problemi economici.
4. Alcune informazioni contenute nella lettera erano presenti in documenti interni.
5. Carlo ed Enrico hanno avuto accesso a tali documenti.
6. Nessuna prova collega direttamente uno dei due alla spedizione della lettera.

Soluzione = Enrico. Aveva accumulato debiti e sperava di ottenere denaro sfruttando informazioni riservate.





CASO 3

Informazioni incomplete: manca un elemento decisivo e nessuna soluzione è completamente supportata.

Il reperto archeologico sostituito

Durante l'inventario annuale di un museo si scopre che un piccolo reperto archeologico è stato sostituito con una copia quasi perfetta. Non è possibile stabilire quando sia avvenuta la sostituzione.

Sospettati:


- Elena (curatrice)
- Paolo (restauratore)
- Marco (responsabile del deposito)

Indizi:

1. Elena gestisce il catalogo dei reperti.
2. Paolo ha esperienza nella realizzazione di copie.
3. Marco controlla gli accessi al deposito.
4. Non risultano effrazioni.
5. La copia è stata realizzata con materiali professionali.
6. Non esistono registrazioni video del periodo in cui la sostituzione potrebbe essere avvenuta.

Soluzione = Paolo. Aveva promesso il reperto originale a un collezionista privato in cambio di denaro.





CASO 4

Indizi contraddittori: alcuni indizi sembrano incompatibili tra di loro.

Il delitto della villa

Durante una cena di beneficenza in una villa privata, il proprietario della villa viene trovato morto nel suo studio. Nessuno ha lasciato la proprietà durante la serata.

Sospettati:

- Claudia (figlia della vittima)
- Giorgio (socio d'affari)
- Vittorio (maggiordomo)

Indizi:

1. Claudia aveva avuto una forte discussione con il padre il giorno prima.
2. Giorgio avrebbe ottenuto vantaggi economici dalla morte della vittima.
3. Vittorio è stato l'ultimo a vedere la vittima viva.
4. Una chiave dello studio viene trovata nella stanza di Claudia.
5. Alcune testimonianze collocano Giorgio lontano dallo studio nell'orario stimato.
6. I registri delle telecamere mostrano che Vittorio è entrato nello studio poco prima dell'accaduto.

Soluzione = Vittorio. Dopo anni di servizio aveva scoperto che sarebbe stato licenziato senza alcuna buonuscita e nutriva un forte risentimento verso il proprietario.



CASO 5

Caso quasi risolto: le prove puntano abbastanza chiaramente verso un sospettato, accordo quasi immediato.

Il sabotaggio della rappresentazione teatrale

Poco prima della prima di uno spettacolo teatrale universitario, il sistema audio smette improvvisamente di funzionare. Lo spettacolo viene rinviato.

Sospettati:

- Alessia (attrice protagonista)
- Federico (tecnico audio)
- Martina (assistente di produzione)

Indizi:

1. Alessia era nervosa per la rappresentazione.
2. Federico aveva accesso esclusivo all'impianto audio.
3. Martina coordinava i preparativi finali.
4. Un componente essenziale dell'impianto è stato scollegato manualmente
5. Le telecamere mostrano Federico vicino alla console poco prima del guasto.
6. Federico aveva espresso dubbi sulla sicurezza dell'attrezzatura e desiderava rinviare l'evento.

Soluzione = Federico. Temeva che un malfunzionamento durante lo spettacolo potesse compromettere la sua reputazione professionale e ha preferito provocare un guasto controllato per ottenere un rinvio.

